Benchmark Méthodologique : Timestral (Mistral AI) vs Économétrie Statistique (R)

Analyse critique sur l'inflation, la hiérarchie sectorielle, le conditionnement par variables exogènes et l'évaluation probabiliste

2026-10-19

1. Introduction & Architecture de Timestral

Timestral est une famille de modèles de fondation ouverts développée par **Mistral AI** pour la prévision de séries temporelles.

Spécifications architecturales

- **Patching temporel** : Les séries temporelles sont partitionnées en patchs disjoints de 32 pas de temps consécutifs (`patch_size: 32`), projetés dans l'espace latent du modèle. L'attention alternée permet de modéliser les dynamiques intra-temporelles et inter-séries.
- **Distribution prédictive** : Une tête de projection dédiée génère directement une grille empirique de quantiles ($q_{0.01}$ à $q_{0.99}$), lue dynamiquement depuis les sorties du modèle. La médiane ($q_{0.50}$) sert d'estimateur ponctuel, tandis que l'ensemble des quantiles permet une évaluation probabiliste complète via des règles de score propres (*Weighted Interval Score* et *CRPS*) sans hypothèse paramétrique gaussienne a priori.
- **Support des covariables (`covariate_enabled: true`)** : L'API `TimestralForecaster` gère les régresseurs exogènes passés (`past_covariates`) et connus sur l'horizon de prévision (`known_covariates`).
- **Modèles évalués** : `Timestral-5M` et `Timestral-209M`.

---

2. Cadre méthodologique & Précautions d'évaluation

Une comparaison empirique rigoureuse entre modèles de fondation et modèles statistiques impose quatre garde-fous méthodologiques intégrés à ce pipeline :

1. **Risque de contamination des données de pré-entraînement** : Les séries macroéconomiques (`CPIAUCSL`, `UNRATE`, `FEDFUNDS`) et les données de ventes au détail du Census Bureau sont omniprésentes dans les banques de données ouvertes. Il est impossible de certifier que leur historique n'appartient pas à des périodes qui ont pu précéder la date de coupe du pré-entraînement de Mistral AI. Le qualificatif *zero-shot* doit être interprété dans cette limite.

2. **Validation multi-origines espacées et tests de Diebold–Mariano** : Une évaluation sur une unique fenêtre de 12 mois (année 2024) souffre d'une forte variance d'échantillonnage et d'une autocorrélation marquée des erreurs. Nous complétons donc l'analyse sur 2024 par une validation en origines roulantes (*rolling-origin evaluation*) sur 24 origines espacées de 6 mois s'étendant de 2012 à 2023, assortie de tests de Diebold–Mariano avec correction de petits échantillons de Harvey, Leybourne & Newbold (1997) en Section 6.
3. **Distributions prédictives exactes (Gaussienne analytique vs Simulation Monte Carlo)** : Pour `forecast::auto.arima`, les quantiles prédictifs sont dérivés analytiquement de la distribution gaussienne exacte de Box-Jenkins (`forecast.Arima`). Pour les modèles de lissage exponentiel sélectionnés par `forecast::ets` pouvant présenter des erreurs multiplicatives ou une tendance amortie (dont la distribution prédictive à plusieurs pas est asymétrique), nous générons directement $B = 3\,000$ trajectoires simulées dans l'espace d'état (`simulate = TRUE` avec innovations gaussiennes, `bootstrap = FALSE`) pour échantillonner fidèlement les quantiles sans recourir à une approximation gaussienne symétrique sur la moyenne finale. Soulignons que ces simulations sont conditionnées à l'état final estimé $\hat{x}_T$ et aux paramètres ponctuels estimés par maximum de vraisemblance, sans intégrer l'incertitude d'estimation des paramètres ni d'innovations empiriques non gaussiennes.
4. **Isolation de la longueur de contexte** : Afin de séparer l'effet pur de la longueur d'historique L du changement de fenêtre temporelle, la Section 6 évalue systématiquement $L \in \{60, 120, 168, 240, 288\}$ mois sur la même série `CPIAUCSL` et la même cible de test (année 2024).

---

3. Étude 1 : Prévision de l'indice des prix (CPI) & Évaluation Probabiliste

Données & Procédure

- **Données** : `CPIAUCSL` (180 mois, entraînement 2010–2023 soit 168 mois, test sur les 12 mois de 2024).
- **Sélection automatique ARIMA & ETS** : La série étant déjà désaisonnalisée par le BLS via X-13ARIMA-SEATS, `forecast::auto.arima` sélectionne ARIMA(0,2,2) et `forecast::ets` identifie ETS(M,A,N) par minimisation du critère AICc.
- **Baselines naïves** : Marche aléatoire simple (*Naive*, RMSE de 5,397) et marche aléatoire avec dérive linéaire historique (*Drift*, RMSE de 1,506). Les quantiles prédictifs de ces baselines sont calculés à partir de la dispersion des innovations historiques estimée de façon robuste par la MAD (`stats::mad(diff(y))`). Si cette estimation par la MAD immunise la variance contre les chocs aberrants ponctuels (comme le pic d'avril 2020 sur le chômage), elle suppose une dérive médiane stationnaire et peut sous-estimer la dispersion des innovations lors de ruptures de régime d'inflation persistantes (telles que le choc 2021–2022).
- **Nature des prévisions ponctuelles** : Pour les modèles statistiques R, la prévision ponctuelle correspond à l'espérance conditionnelle $\hat{y}_{T+h} = \mathbb{E}[y_{T+h} \mid \mathcal{F}_T]$ (`fc$mean`). Pour Timestral, l'estimateur ponctuel utilisé est la médiane prédictive centrale $q_{0.50}$.

- **Métriques d'étalonnage** : *Relative RMSE* ($rRMSE = \text{RMSE}_{\text{modèle}}/\text{RMSE}_{\text{naive}}$) et *Scaled WIS* ($sWIS = \text{WIS}_{\text{modèle}}/\text{WIS}_{\text{naive}}$).

Résultats ponctuels (CPI, horizon 2024)

Modèle	Spécification	RMSE	MAE	rRMSE (vs Naive)	Inflation Prédite (%)	Inflation Réelle (%)
Naive (Marche aléatoire)	RW(0)	5.3971	4.9572	1.000	0.00	2.87
RW avec Dérive (Drift)	RW+drift	1.5061	1.4054	0.279	2.12	2.87
R ARIMA (AIC)	ARIMA(0,2,2)	1.0807	0.9895	0.200	3.26	2.87
R ETS (Espace d'états)	ETS(M,A,N)	0.7450	0.5390	0.138	2.70	2.87
R Ensemble (ARIMA+ETS)	ARIMA(0,2,2)+ETS(M,A,N)	0.7741	0.6097	0.144	2.98	2.87
Timestral-5M (Zero-shot)	Patch=32, 5M, L=168	0.9136	0.7558	0.169	2.43	2.87
Timestral-209M (Zero-shot)	Patch=32, 209M, L=168	1.4106	1.2754	0.261	2.08	2.87

Évaluation Probabiliste : Pinball Loss, WIS, CRPS & Couverture d'Intervalles

L'évaluation ponctuelle (RMSE / MAE) ne renseigne pas sur la calibration de la distribution prédictive complète. Nous évaluons sur la grille des 21 quantiles natifs : - La **Pinball Loss moyenne** :

$$L_\tau(y, \hat{q}_\tau) = \max(\tau(y - \hat{q}_\tau), (1-\tau)(\hat{q}_\tau - y))$$

- Le **Weighted Interval Score (WIS)** (Bracher et al., 2021), règle de score propre combinant l'erreur absolue médiane et les scores d'intervalles sur 10 intervalles centraux, ainsi que le **CRPS** approché par intégration de Riemann pondérée par les largeurs de cellules de probabilité $\Delta\tau_k$. - Le **taux de couverture empirique** à 80 % ($[q_{0.10}, q_{0.90}]$) et à 90 % ($[q_{0.05}, q_{0.95}]$), accompagné de la **largeur moyenne des intervalles** (`width_80`, `width_90`) et du nombre d'inversions de quantiles brutes (`crossings`).

Modèle	Méthode de distribution	sWIS	WIS	CRPS	Pinball	Couv. 80%	Couv. 90%	Largeur 80%	Largeur 90%	Inversions
Naive (Marche aléatoire)	RW gaussien (innovations 1-pas)	1.000	4.164	4.252	2.080	0.000	0.000	3.19	4.09	0
RW avec Dérive (Drift)	RW+dérive gaussien	0.210	0.874	0.912	0.437	0.583	0.833	3.19	4.09	0

Modèle	Méthode distribution	WIS	WIS/RMSE	CRPS	Pinball	Couv. 80%	Couv. 90%	Largeur 80%	Largeur 90%	Inversions
R ARIMA	ARIMA(0,2,2) (analytique)	0.190	0.793	0.823	0.397	1.000	1.000	7.39	9.49	0
R ETS	ETS(M,A,N) (simulé, B=3000)	0.220	0.916	0.949	0.458	1.000	1.000	9.19	11.81	0
R Ensemble	Moyenne de quantiles (ARIMA+ETS)	0.199	0.827	0.857	0.414	1.000	1.000	8.29	10.65	0
Timestral-5M	21 quantiles natifs (L=168)	0.189	0.787	0.811	0.393	1.000	1.000	7.82	11.70	0
Timestral-209M	21 quantiles natifs (L=168)	0.217	0.902	0.928	0.451	0.917	1.000	7.18	11.83	0

Analyse

- **Scores propres (WIS & CRPS) vs erreur ponctuelle** : Sur cette fenêtre de 12 mois, R ETS (Espace d'états) obtient le RMSE ponctuel le plus bas (0,745, soit $rRMSE = 0{,}138$), tandis que `Timestral-5M` présente un RMSE de 0,914 ($rRMSE = 0{,}169$) et `Timestral-209M` un RMSE de 1,411. Sur le plan probabiliste, Timestral-5M obtient sur cet échantillon le WIS le plus faible (0,787) et Timestral-5M le CRPS le plus faible (0,811), devant ETS(M,A,N) (WIS de 0,916, CRPS de 0,949) et ARIMA(0,2,2) (WIS de 0,793, CRPS de 0,823).
- **Interprétation critique de la couverture et monotonicité des quantiles** : Les modèles affichent des couvertures empiriques comprises entre 0,00 et 1,00 à 80 % et entre 0,00 et 1,00 à 90 %. Le nombre d'inversions de quantiles est strictement nul (`crossings = 0`) : si cette monotonie est triviale pour ARIMA (fonction quantile gaussienne analytique) et pour ETS (trajectoires Monte Carlo ordonnées), elle montre que la tête neuronale de régression multi-quantiles de Timestral n'a pas révélé d'inversion sur cette application. Sur un horizon de test restreint à 12 mois consécutifs fortement autocorrélés, les taux de couverture empiriques observés ne permettent pas de conclure formellement à une sur- ou sous-calibration asymptotique, mais reflètent la largeur relative des bandes d'incertitude face au profil réalisé de l'inflation en 2024. La largeur moyenne d'intervalles (`width_80`) discrimine nettement les approches : Naive (Marche aléatoire) génère les intervalles les plus resserrés (3,19 points d'indice), alors que R ETS produit les plus larges (9,19 points d'indice).

---

4. Étude 2 : Ventes au détail sectorielles & Réconciliation Hiérarchique (MinT-shrink)

Structure de l'arbre hiérarchique

Les données du *Monthly Retail Trade Survey* (FRED / US Census Bureau) comprennent le Total des ventes au détail (`total`) et 5 sous-secteurs majeurs (`automotive`, `food_beverage`, `clothing`,

ecommerce, general_merchandise). Afin de fermer mathématiquement la hiérarchie ($Total_t \equiv \sum_{j=1}^{6} b_{j,t}$), nous isolons la composante résiduelle other :

$$\mathbf{y}_t = \begin{pmatrix} y_{\text{Total},t} \\ \mathbf{b}_t \end{pmatrix} = \mathbf{S}\mathbf{b}_t, \quad \mathbf{S} = \begin{pmatrix} \mathbf{1}_6^T \\ \mathbf{I}_6 \end{pmatrix} \in \mathbb{R}^{7\times 6}$$

Précision de nomenclature : La série ecommerce correspond à la série officielle RSNSR du Census Bureau (**Détaillants hors magasin**, *Nonstore Retailers*, code NAICS 454), tandis que general_merchandise correspond aux **Magasins de marchandises diverses** (*General Merchandise Stores*, code NAICS 452).

Réconciliation MinT avec rétrécissement sur la matrice de corrélation (MinT-shrink)

Pour comparer équitablement les modèles statistiques et les modèles de fondation, nous appliquons les **deux mêmes opérateurs de réconciliation** — agrégation **Bottom-Up (_bu)** et projection **MinT-shrink (_mint)** — aux **quatre familles de modèles** (ARIMA, ETS, Timestral-5M, Timestral-209M).

Conformément à Wickramasuriya, Athanasopoulos & Hyndman (2019) et Schäfer & Strimmer (2005), les séries ayant des échelles très différentes (total autour de 700 000 M$ contre clothing autour de 25 000 M$), l'intensité optimale de rétrécissement $\hat{\lambda} \in [0,1]$ est calculée sur les **résidus standardisés** (rétrécissement de la matrice de corrélation empirique $\mathbf{R}$ vers $\mathbf{I}_7$), puis re-pondérée par les écarts-types résiduels $\mathbf{D} = \text{diag}\,(\hat{\sigma}_1, \ldots, \hat{\sigma}_7)$:

$$\mathbf{W}_1 = \mathbf{D}\Big((1-\hat{\lambda})\mathbf{R} + \hat{\lambda}\mathbf{I}_7\Big)\mathbf{D}, \quad \mathbf{P}_{\text{MinT}} = (\mathbf{S}^T\mathbf{W}_1^{-1}\mathbf{S})^{-1}\mathbf{S}^T\mathbf{W}_1^{-1}, \quad \tilde{\mathbf{y}}_{T+h} = \mathbf{S}\mathbf{P}_{\text{MinT}}\hat{\mathbf{y}}_{T+h}$$

Précision méthodologique sur $\mathbf{W}_1$: Pour ARIMA et ETS, $\mathbf{W}_1$ est estimée à partir des résidus bruts d'ajustement in-sample (residuals(fit, type = 'response'), $t = 13 \ldots 168$). Pour Timestral (modèle pré-entraîné sans résidus d'ajustement in-sample), $\mathbf{W}_1$ est estimée à partir des erreurs de prévision one-step-ahead sur 48 origines roulantes historiques à l'intérieur de l'échantillon d'entraînement. Conformément à l'hypothèse standard de proportionnalité de Wickramasuriya et al. (2019) ($\mathbf{W}_h \approx k_h \mathbf{W}_1$), cette même matrice $\mathbf{P}_{\text{MinT}}$ est appliquée aux horizons $h = 1 \ldots 12$.

Vérification de la cohérence comptable

Le tableau ci-dessous est dédié exclusivement à la vérification de la contrainte d'agrégation ($\max_{h\in\{1..12\}} \left| \hat{y}_{\text{total},h} - \sum_{j=1}^{6} \hat{y}_{j,h} \right|$) et aux intensités de rétrécissement $\hat{\lambda}$ estimées :

Méthode & Réconciliation	Réconcilié (0/1)	Lambda Shrinkage	RMSE Total	RMSE Moyen Sous-Secteurs	Incohérence Max (M$)
R ARIMA (Base non réconcilié)	0	0.0000	9173.4	2200.4	4660
R ARIMA (Bottom-Up)	1	0.0000	11154.4	2200.4	0

Méthode & Réconciliation	Réconcilié (0/1)	Lambda Shrinkage	RMSE Total	RMSE Moyen Sous-Secteurs	Incohérence Max (M$)
R ARIMA (MinT-shrink)	1	0.3511	10920.8	2173.4	0
R ETS (Base non réconcilié)	0	0.0000	8633.8	2684.6	3450
R ETS (Bottom-Up)	1	0.0000	11220.8	2684.6	0
R ETS (MinT-shrink)	1	0.3027	10528.7	2601.5	0
Timestral-5M (Base non réconcilié)	0	0.0000	6560.2	2529.0	6150
Timestral-5M (Bottom-Up)	1	0.0000	7354.1	2529.0	0
Timestral-5M (MinT-shrink backtest)	1	0.3510	6916.5	2516.9	0
Timestral-209M (Base non réconcilié)	0	0.0000	6589.5	2377.8	760
Timestral-209M (Bottom-Up)	1	0.0000	6438.3	2377.8	0
Timestral-209M (MinT-shrink backtest)	1	0.4086	6464.5	2379.3	0

Résultats sectoriels (RMSE ponctuel & WIS probabiliste)

Secteur	Naive (RW)	ARIMA Base	ARIMA MinT	ETS Base	ETS MinT	T5M Base	T5M MinT	T209M Base	T209M MinT	WIS ARIMA	WIS ETS	WIS T5M	WIS T209M
Total	10752.5	9173.4	10920.8	8633.8	10528.7	6560.2	6916.5	6589.5	6464.5	6696.7	6463.5	6145.6	4448.9
Automobile	2955.5	5533.8	5414.4	5796.6	5459.2	4424.3	4129.8	2974.8	2977.8	3064.3	3229.2	2495.0	1878.7
Alimentation	1312.8	584.9	576.2	1312.8	1378.4	1646.1	1475.3	1403.8	1404.5	1141.6	1440.9	959.8	868.5
Habillement	348.0	365.5	371.1	348.0	338.5	300.4	307.0	328.7	329.3	562.6	763.2	167.6	181.7
Commerce hors magasin (ecommerce)	2220.4	4358.3	4354.6	4337.0	4318.3	3577.4	3591.7	3190.6	3190.0	2620.2	3444.2	2212.5	2017.4
Marchandises diverses (NAICS 452)	1671.3	431.9	429.2	1392.2	1405.0	1114.4	1143.8	1274.5	1274.7	418.6	765.8	611.0	673.7
Autres secteurs	4167.9	1927.8	1894.8	2921.2	2709.9	4111.2	4453.7	5094.3	5099.7	1958.2	3385.2	2424.9	2691.3

Analyse

- **Restauration exacte de la cohérence** : Les prévisions de base non réconciliées (`base`) violent la contrainte comptable avec des incohérences maximales allant de 760 M$ (`Timestral-209M`) à 6150 M$ (`Timestral-5M`), 4660 M$ (`ARIMA`) et 3450 M$ (`ETS`). Les projections `bottom_up` et `mint_shrink` réduisent cette incohérence au bruit numérique de virgule flottante (1.16^{-10} M$, vérifié par assertion stricte $< 10^{-8} \times 750\,000$ dans le pipeline).
- **Effet nuancé de la réconciliation sur le Total** : Contrairement à une idée reçue, ni le *Bottom-Up* ni *MinT-shrink* n'améliorent mécaniquement le RMSE du Total pour tous les modèles :
  - Pour `Timestral-209M`, la réconciliation améliore la prévision du Total : le RMSE passe de 6589,5 M$ (`base`) à 6438,3 M$ (`bottom_up`) et 6464,5 M$ (`mint_shrink`).
  - Pour `Timestral-5M`, la prévision directe du Total (`base` : 6560,2 M$) est plus précise que l'agrégation *bottom-up* (7354,1 M$), et la projection `mint_shrink` établit un compromis cohérent à 6916,5 M$.
  - Pour `ARIMA` et `ETS`, la réconciliation `mint_shrink` améliore le *Bottom-Up* sur le Total pour ARIMA (10920,8 contre 11154,4 M$) et améliore pour ETS (10528,7 contre 11220,8 M$) ainsi que les sous-secteurs, bien que la prévision directe non réconciliée du Total reste inférieure en RMSE (8633,8 M$ pour ETS).
- **Comparaison sectorielle sous réconciliation MinT-shrink** : Sur le Total réconcilié par MinT-shrink, Timestral-209M obtient le RMSE le plus bas (6464,5 M$), devant les autres modèles (ARIMA : 10920,8 M$, ETS : 10528,7 M$, Timestral-5M : 6916,5 M$, Timestral-209M : 6464,5 M$). Sur les sous-secteurs d'activité, les modèles se partagent les meilleures performances : `Timestral-209M` l'emporte sur Automobile, Commerce hors magasin (ecommerce), `Timestral-5M` sur Habillement, `ARIMA` sur Alimentation, Marchandises diverses (NAICS 452) et `ETS` sur aucun secteur.

---

5. Étude 3 : Triptyque Macroéconomique & Conditionnement Exogène

Régime Ex-ante vs Scénario Conditionnel (Oracle)

L'échantillon couvre 300 mois (2000–2024 : 288 mois d'entraînement 2000–2023, 12 mois de test sur 2024) pour le CPI (`CPIAUCSL`), le chômage (`UNRATE`) et le taux directeur de la Fed (`FEDFUNDS`). Nous séparons strictement : 1. **Régime Ex-ante Inconditionnel** : Aucune information future sur 2024 n'est fournie. Le modèle vectoriel autorégressif VAR(p=6, AIC) (ordre sélectionné dynamiquement par `VARselect` avec critère AIC) prévoit conjointement les trois variables de manière endogène, aux côtés des modèles univariés (`Naive`, `ARIMA`, `ETS`, `Timestral-5M`, `Timestral-209M`). 2. **Régime Conditionnel de Scénario (Oracle `FEDFUNDS`)** : Les modèles reçoivent la trajectoire réalisée de `FEDFUNDS` en 2024 comme variable exogène connue (`xreg` pour ARIMAX(3,2,3,0,0,1,12), `known_covariates` pour Timestral). Il s'agit d'un exercice de prévision conditionnelle (stress-test / scénario de politique monétaire) et non d'une prévision ex-ante.

Résultats comparatifs sur l'année 2024 (Ponctuels & Probabilistes)

Cible	Régime	Modèle	Spécification	RMSE	rRMSE (vs Naive)	SWIS	SWCS	CRPS	Couv. 80%	Couv. 90%	Largeur 80%	Inversions
CPI (Inflation)	Ex-ante Inconditionnel	Naive (Dernière valeur)	RW(0)	5.397	1.000	1.004	0.234	2.315	0.000	0	2.90	0
CPI (Inflation)	Ex-ante Inconditionnel	R ARIMA	ARIMA(2,2,3)	2.253	0.418	0.245	0.138	0.811	1.000	1	6.86	0
CPI (Inflation)	Ex-ante Inconditionnel	R ETS	ETS(M,Ad,N)	3.911	0.725	0.348	0.203	1.131	1.000	1	13.07	0
CPI (Inflation)	Ex-ante Inconditionnel	VAR multivarié	VAR(p=1, AIC)	1.107	0.205	NA	NA	NA	NA	NA	NA	0
CPI (Inflation)	Ex-ante Inconditionnel	Timestral-5M Univarié	L=288, sans cov.	1.062	0.197	0.197	0.097	0.782	0.833	1	6.29	0
CPI (Inflation)	Ex-ante Inconditionnel	Timestral-209M Univarié	L=288, sans cov.	1.113	0.206	0.209	0.084	0.907	1.000	1	8.81	0
CPI (Inflation)	Conditionnel (Oracle FedFunds)	ARIMAX (avec FedFunds)	ARIMAX(3,2,3)	0.875	0.162	0.074	0.038	0.766	1.000	1	6.70	0
CPI (Inflation)	Conditionnel (Oracle FedFunds)	Timestral-5M (avec FedFunds)	L=288 + known_cov	1.434	0.266	0.268	0.089	1.021	0.833	1	6.22	0
CPI (Inflation)	Conditionnel (Oracle FedFunds)	Timestral-209M	L=288 + known_cov	0.979	0.181	0.187	0.054	0.777	1.000	1	7.44	0

Cible	Régime	Modèle	Spécification	RMSE	rRMSE (vs Naive)	MAE	MASE	WIS	CRPS	Couv. 80%	Couv. 90%	Largeur 80%	Inversions
flation)		(avec FedFunds)											
UNRATE (Chômage)	Ex-ante Inconditionnel	Naive (Dernière valeur)	RW(0)	0.272	1.000	0.146	1.000	0.146	0.152	1.000	1	0.93	0
UNRATE (Chômage)	Ex-ante Inconditionnel	R ARIMA	ARIMA(0,2,2)	0.272	1.002	0.238	1.633	0.239	0.261	1.000	1	4.19	0
UNRATE (Chômage)	Ex-ante Inconditionnel	R ETS	ETS(M,A,N)	0.485	1.781	0.281	1.923	0.281	0.323	1.000	1	13.69	0
UNRATE (Chômage)	Ex-ante Inconditionnel	VAR multivarié	VAR(p=6, AIC)	1.075	3.947	NA	NA	NA	NA	NA	NA	NA	0
UNRATE (Chômage)	Ex-ante Inconditionnel	Timestral-5M Univarié	L=288, sans cov.	0.152	0.560	0.076	0.521	0.076	0.111	1.000	1	1.07	0
UNRATE (Chômage)	Ex-ante Inconditionnel	Timestral-209M Univarié	L=288, sans cov.	0.146	0.536	0.071	0.490	0.071	0.101	1.000	1	0.87	0
UNRATE (Chômage)	Conditionnel (Oracle FedFunds)	ARIMAX (avec FedFunds)	ARIMAX(7,1,1)	0.711	2.612	0.564	3.863	0.564	0.743	1.000	1	3.16	0
UNRATE (Chômage)	Conditionnel (Oracle FedFunds)	Timestral-5M (avec FedFunds)	L=288 + known_cov	0.217	0.798	0.088	0.603	0.088	0.122	1.000	1	0.64	0
UNRATE (Chômage)	Conditionnel (Oracle FedFunds)	Timestral-209M (avec FedFunds)	L=288 + known_cov	0.171	0.628	0.064	0.439	0.064	0.098	0.917	1	0.54	0

Analyse critique des résultats

- **Taux de chômage (`UNRATE`) et baseline naïve** : Sur l'année 2024, la marche aléatoire (`Naive`) affiche un RMSE de 0,272 point de pourcentage. Estimés sur 24 ans d'historique (2000–2023), le modèle VAR(p=6, AIC) (RMSE de 1,075, soit $rRMSE = 3{,}95$) et l'ARIMAX conditionnel (RMSE de 0,711, $rRMSE = 2{,}61$) affichent une erreur supérieure à la baseline naïve ; une conjecture explicative réside dans la sensibilité de ces spécifications linéaires au niveau excep-

tionnellement élevé des taux d'intérêt en 2024. En régime ex-ante inconditionnel, le modèle Timestral-209M Univarié atteint le RMSE le plus faible (0,146, $rRMSE = 0{,}54$, WIS de 0,098). L'ajout de `FEDFUNDS` en covariable modifie la prévision sur 2024 (`Timestral-209M` passe à 0,171 et `Timestral-5M` à 0,217).

- **Inflation (`CPI`) et conditionnement exogène** : En régime ex-ante sur la fenêtre de 288 mois, Timestral-5M Univarié obtient le RMSE le plus bas (1,062, WIS de 0,759), devant les modèles statistiques traditionnels (ETS(M,Ad,N) : RMSE de 3,900, ARIMA(0,2,2) : 2,053) et `Timestral-209M` (RMSE de 1,113, WIS de 0,884). En régime conditionnel (Oracle `FEDFUNDS`), `Timestral-209M` enregistre une amélioration de sa précision ponctuelle (RMSE passant de 1,113 à 0,979, WIS de 0,884 à 0,754), tandis que `Timestral-5M` enregistre une dégradation (RMSE de 1,062 à 1,434).

---

6. Ablation de la Longueur de Contexte & Validation en Origines Roulantes (Diebold–Mariano)

6.1 Ablation contrôlée de la longueur de contexte sur la même série CPI

Pour vérifier pourquoi `Timestral-5M` passe d'un RMSE de 0,914 dans l'Étude 1 ($L = 168$ mois, 2010–2023) à 1,062 dans l'Étude 3 ($L = 288$ mois, 2000–2023), nous évaluons $L \in \{60, 120, 168, 240, 288\}$ mois en tronquant exactement la **même série `CPIAUCSL`** (les 180 dernières observations de `macro_triad.csv` étant identiques au fichier `cpi.csv` à $0, 0$ près, vérifié par assertion), toutes les fenêtres se terminant en décembre 2023 et étant évaluées sur la même cible 2024 :

Longueur L (mois)	Début fenêtre	Spéc. ARIMA	Spéc. ETS	RMSE ARIMA	RMSE ETS	RMSE Timestral-5M	RMSE Timestral-209M
60	2019-01	ARIMA(0,2,3)	ETS(M,Ad,N)	1.7272	0.8695	1.4736	1.7856
120	2014-01	ARIMA(1,2,2)	ETS(M,Ad,N)	1.7886	0.8237	1.4068	1.6200
168	2010-01	ARIMA(0,2,2)	ETS(M,Ad,N)	1.0807	0.7450	0.9136	1.4106
240	2004-01	ARIMA(0,2,2,0,0,12)	ETS(A,Ad,N)	2.1521	3.8621	0.9188	1.4230
288	2000-01	ARIMA(0,2,2,0,0,12)	ETS(M,Ad,N)	2.0527	3.8998	1.0618	1.1131

- **Interprétation** : Pour `Timestral-209M`, l'évolution du RMSE en fonction de la longueur de contexte L est fortement favorable à l'allongement de l'historique (corrélation de $-0{,}95$ avec L) : le RMSE passe de 1,786 ($L = 60$) à 1,620 ($L = 120$), 1,411 ($L = 168$) et 1,113 ($L = 288$), avec un minimum atteint à $L = 288$. Pour `Timestral-5M`, l'optimum sur cette cible est atteint pour $L = 168$ (RMSE de 0,914), avant de remonter à 1,062 lorsque la fenêtre s'étend à $L = 288$ (une conjecture plausible étant l'inclusion des années 2000–2003, marquées par la récession post-bulle Internet et un cycle d'assouplissement monétaire atypique, alors que $L = 240$ débute en 2004 et intègre déjà la crise financière de 2008). Notons que modifier L en gardant la date de fin fixe modifie simultanément le nombre de patchs fournis au modèle et les régimes macroé-

conomiques historiques inclus dans la fenêtre, de sorte que cette explication conjoncturelle demeure une hypothèse de travail.

6.2 Évaluation en Origines Roulantes (24 fenêtres espacées) & Tests de Diebold–Mariano

Afin de dépasser les limites d'une seule fenêtre de 12 mois, nous exécutons une validation en origines roulantes sur $N = 24$ origines espacées de 6 mois ($L \in \{150, 156, \ldots, 288\}$, couvrant la période 2012–2023) pour `CPI` et `UNRATE`. Nous distinguons rigoureusement trois horizons d'évaluation : 1. **Pas 1 ($h = 1$)** : Erreurs ponctuelles à 1 mois d'horizon (24 observations espacées de 6 mois, statistiquement indépendantes). 2. **Pas 12 ($h = 12$)** : Erreurs ponctuelles à 12 mois d'horizon (24 observations espacées de 6 mois, chevauchant temporellement de 6 mois). L'autocorrélation effective s'étend donc sur $\lceil 12/6 \rceil = 2$ pas d'échantillon : le test de Diebold–Mariano est paramétré avec $h = 2$ retards (noyau de Bartlett tronqué à 1 retard), ce qui réduit le risque de variance de Bartlett négative sur cet échantillon ($N = 24$). 3. **Trajectoire (1..12 m)** : Métriques agrégées sur l'intégralité de la trajectoire annuelle de 12 mois. Le RMSE de trajectoire correspond à la racine de la moyenne des erreurs quadratiques moyennes des 24 fenêtres ($\mathrm{RMSE}_{\mathrm{traj}} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} \mathrm{MSE}_i}$), tandis que le MAE est la moyenne arithmétique simple des MAE individuels ($\mathrm{MAE}_{\mathrm{traj}} = \frac{1}{N}\sum_{i=1}^{N} \mathrm{MAE}_i$), accompagnés du WIS, du CRPS et de la couverture à 80 % (avec baselines naïves évaluées via l'échelle robuste MAD).

Rappel sur le risque de contamination : Les 24 fenêtres d'évaluation s'étendant de 2012 à 2024, les données de test appartiennent à une période historique qui a pu précéder la date de coupe du pré-entraînement de Timestral. Les performances observées doivent donc être interprétées avec la réserve méthodologique liée à la possible observation préalable de ces dynamiques historiques.

Cible	Horizon	Modèle	RMSE	MAE	RMSE Hors-Covid	MAE Hors-Covid	WIS	CRPS	Couv. 80%	Stat DM (vs ARIMA)	p-val DM (Harvey)
CPI (24 origines)	Pas 1 (h=1)	Naive (RW)	0.826	0.651	0.847	0.660	NA	NA	NA	0.134	0.894
CPI (24 origines)	Pas 1 (h=1)	R ARIMA (réf. DM)	0.790	0.493	0.821	0.515	NA	NA	NA	NA	NA
CPI (24 origines)	Pas 1 (h=1)	R ETS	0.739	0.463	0.761	0.476	NA	NA	NA	−0.690	0.497
CPI (24 origines)	Pas 1 (h=1)	Timestral-5M	0.832	0.493	0.866	0.518	NA	NA	NA	0.646	0.525
CPI (24 origines)	Pas 1 (h=1)	Timestral-240M	0.750	0.464	0.784	0.483	NA	NA	NA	−1.105	0.281

Cible	Horizon	Modèle	RMSE	MAE	RMSE Hors-Covid	MAE Hors-Covid	WIS	CRPS	Couv. 80%	Stat DM (vs ARIMA)	p-val DM (Harvey)
CPI (24 origines)	Pas 12 (h=12)	Naive (RW)	9.267	7.121	9.641	7.530	NA	NA	NA	2.206	0.038
CPI (24 origines)	Pas 12 (h=12)	R ARIMA (réf. DM)	7.184	6.636	7.486	4.909	NA	NA	NA	NA	NA
CPI (24 origines)	Pas 12 (h=12)	R ETS	6.773	6.275	7.066	5.632	NA	NA	NA	−0.392	0.699
CPI (24 origines)	Pas 12 (h=12)	Time-tral-5M	6.344	6.086	6.610	4.327	NA	NA	NA	−1.067	0.297
CPI (24 origines)	Pas 12 (h=12)	Timestral-2M	6.714	6.291	6.999	4.564	NA	NA	NA	−0.890	0.383
CPI (24 origines)	Trajectoire (1..12m)	Naive (RW)	5.657	7.932	5.873	4.123	7.313	1.378	0.215	NA	NA
CPI (24 origines)	Trajectoire (1..12m)	R ARIMA (réf. DM)	4.272	3.468	4.416	2.537	7.895	1.954	0.771	NA	NA
CPI (24 origines)	Trajectoire (1..12m)	R ETS	4.002	6.924	4.121	3.013	3.963	2.046	0.892	NA	NA
CPI (24 origines)	Trajectoire (1..12m)	Time-tral-5M	3.845	5.391	3.967	2.461	0.681	1.745	0.799	NA	NA
CPI (24 origines)	Trajectoire (1..12m)	Timestral-2M	4.112	6.489	4.245	2.561	1.721	1.788	0.799	NA	NA
UNRATE (24 origines)	Pas 1 (h=1)	Naive (RW)	0.226	0.146	0.235	0.155	NA	NA	NA	1.430	0.166
UNRATE (24 origines)	Pas 1 (h=1)	R ARIMA	0.221	0.137	0.230	0.144	NA	NA	NA	NA	NA

Cible	Horizon	Modèle	RMSE	MAE	RMSE Hors-Covid	MAE Hors-Covid	WIS	CRPS	Couv. 80%	Stat DM (vs ARIMA)	p-val DM (Harvey)
		(réf. DM)									
UNRATE (24 origines)	Pas 1 (h=1)	R ETS	0.243	0.161	0.252	0.168	NA	NA	NA	1.692	0.104
UNRATE (24 origines)	Pas 1 (h=1)	Timestral-5M	0.165	0.131	0.171	0.138	NA	NA	NA	−0.986	0.334
UNRATE (24 origines)	Pas 1 (h=1)	Timestral-20M	0.132	0.099	0.138	0.113	NA	NA	NA	−1.140	0.266
UNRATE (24 origines)	Pas 12 (h=12)	Naive (RW)	2.151	1.296	1.464	0.936	NA	NA	NA	−0.809	0.426
UNRATE (24 origines)	Pas 12 (h=12)	R ARIMA (réf. DM)	2.221	1.229	1.439	0.835	NA	NA	NA	NA	NA
UNRATE (24 origines)	Pas 12 (h=12)	R ETS	2.201	1.227	1.457	0.843	NA	NA	NA	−0.429	0.672
UNRATE (24 origines)	Pas 12 (h=12)	Timestral-5M	1.810	1.946	0.808	0.552	NA	NA	NA	−1.596	0.124
UNRATE (24 origines)	Pas 12 (h=12)	Timestral-20M	1.832	2.093	0.775	0.511	NA	NA	NA	−1.557	0.133
UNRATE (24 origines)	Trajectoire (1..12m)	Naive (RW)	1.848	1.833	1.107	0.593	0.707	0.719	0.691	NA	NA
UNRATE (24 origines)	Trajectoire (1..12m)	R ARIMA (réf. DM)	1.865	1.794	1.091	0.538	0.674	0.693	0.865	NA	NA

Cible	Horizon	Modèle	RMSE	MAE	RMSE Hors-Covid	MAE Hors-Covid	WIS	CRPS	Couv. 80%	Stat DM (vs ARIMA)	p-val DM (Harvey)
UNRATE (24 origines)	Trajectoire (1..12m)	R ETS	1.869	0.793	1.106	0.540	0.810	0.835	0.899	NA	NA
UNRATE (24 origines)	Trajectoire (1..12m)	Timestral-5M	1.629	0.624	0.610	0.362	0.510	0.521	0.844	NA	NA
UNRATE (24 origines)	Trajectoire (1..12m)	Timestral-209M	1.638	0.691	0.593	0.343	0.499	0.510	0.854	NA	NA

- **Horizon Pas 1 ($h = 1$)** : Sur 24 origines à 1 pas d'avance sur le `CPI`, le modèle affichant le RMSE le plus bas est R ETS (0,739), suivi des autres modèles classés par RMSE croissant : Timestral-209M (0,755, DM p = 0,281), R ARIMA (réf. DM) (0,790), Naive (RW) (0,826, DM p = 0,894), Timestral-5M (0,832, DM p = 0,525), Timestral-5M (6,345, DM p = 0,297), Timestral-209M (6,717, DM p = 0,383), R ETS (6,778, DM p = 0,699), R ARIMA (réf. DM) (7,186), Naive (RW) (9,264, DM p = 0,038). Sur `UNRATE` à $h = 1$, le modèle le plus précis est Timestral-209M (0,134).
- **Horizon Pas 12 ($h = 12$)** : À l'horizon de 12 mois sur 24 origines roulantes, le modèle présentant le RMSE le plus bas sur le `CPI` est Timestral-5M (6,345, test DM vs ARIMA $p = 0{,}297$) et sur `UNRATE` Timestral-5M (1,815, test DM vs ARIMA $p = 0{,}124$).
- **Trajectoire complète (1..12 m)** : Sur l'ensemble des 12 mois de prévision, le WIS moyen le plus bas sur le CPI est obtenu par Timestral-5M (WIS de 1,684, CRPS de 1,745), tandis que sur UNRATE le modèle le mieux classé en WIS est Timestral-209M (WIS de 0,499). L'évaluation multi-quantiles n'a pas révélé d'inversion de quantiles sur l'ensemble des prévisions générées par les modèles de fondation.
- **Impact du choc Covid sur l'évaluation du chômage** : Le pic historique du printemps 2020 (hausse maximale de 10,4 points en un seul mois sur le chômage) frappe de plein fouet les fenêtres de test contenant mars-avril 2020. L'exclusion de ces origines réduit le RMSE de trajectoire sur le chômage de 40,1 % à 63,8 % selon les modèles (réduction moyenne de 49,7 %). Les colonnes `RMSE Hors-Covid` et `MAE Hors-Covid` montrent que sur ce sous-échantillon sans crise sanitaire extrême, les écarts entre la baseline naïve, ARIMA et Timestral se resserrent, reflétant la persistance du chômage américain en régime normal.
- **Synthèse des tests de significativité & Risque de tests multiples** : Sur les 16 tests de Diebold–Mariano théoriquement calculables avec la correction de Harvey ($h = 1$ et $h = 2$), 16 ont pu être estimés avec succès . Parmi eux, 1 test(s) franchi(ssent) le seuil nominal de 5 %. Sous l'hypothèse nulle globale d'absence de différence de performance prédictive, on s'attend à observer en moyenne 0,8 faux positif(s) au seuil nominal $\alpha = 0,05$ ($16 \times 0,05$). Aucune différence ne résiste à une correction pour tests multiples (procédure de Holm au seuil de 5 %).

Ces résultats n'établissent donc pas de supériorité systématique entre les modèles de fondation et les modèles statistiques sur cet historique.

---

7. Synthèse comparative globale

Dimension	Modèles Statistiques R (ARIMA / ETS / MinT / VAR)	Timestral-5M	Timestral-209M
Observations empiriques (Ponctuel & WIS)	Précision compétitive à court horizon ($h = 1$) et sur les séries tendancielles régulières (`CPI` avec ETS(M,A,N), secteurs Alimentation, Marchandises diverses (NAICS 452))	RMSE le plus bas sur le CPI roulant à h=12 (6,345) et intervalles resserrés sur 2024 (WIS de 0,787)	RMSE observé le plus bas sur le Total des ventes au détail réconcilié (6464,5 M$) et secteurs Automobile, Commerce hors magasin (ecommerce)
Cohérence hiérarchique	Restaurée exactement par MinT-shrink ($\hat{\lambda}_{\text{ETS}} =$ 0,303, incohérence 1.16^{-10} M$)	Restaurée par Bottom-Up ou MinT-shrink ($\hat{\lambda} =$ 0,351, incohérence 1.16^{-10} M$)	Gain simultané de cohérence et de RMSE sur le Total via Bottom-Up (6438,3 M$) et MinT-shrink (6464,5 M$)
Variables exogènes (Scénario Oracle)	Paramétrisation linéaire explicite (`ARIMAX`), sensible aux ruptures de tendance sur `UNRATE`	Dégradation sur le scénario de taux 2024 (`CPI` de 1,062 à 1,434)	Amélioration sur le scénario `CPI` 2024 (RMSE de 1,113 à 0,979)
Distribution prédictive	Quantiles dérivés analytiquement (ARIMA) ou par simulation Monte Carlo exacte (ETS, $B =$ 3 000)	Grille de 21 quantiles natifs sans inversion (`crossings = 0`)	Grille de 21 quantiles natifs sans inversion (`crossings = 0`)
Limites méthodologiques	Sensibilité au choix de différenciation (I(2) élargit fortement les intervalles à $h =$ 12)	Sensibilité au conditionnement exogène et aux régimes historiques inclus dans L	Coût d'inférence plus élevé et opacité du corpus de pré-entraînement vis-à-vis

Dimension	Modèles Statistiques R (ARIMA / ETS / MinT / VAR)	Timestral-5M	Timestral-209M
			des séries publiques FRED